

PLANO DE PROJETO · VERSÃO 2 · SUBSTITUI O RASCUNHO DO EXCALIDRAW

Panorama Eleitoral 2026

Pipeline de coleta e análise de redes sociais para acompanhar, ao longo do tempo, **quais temas** estão associados a cada político e **qual a opinião** (sentimento) do público sobre cada tema — com arquitetura preparada para adicionar novos candidatos e novas fontes sem retrabalho.

ESCOPO V1 LULA · FLÁVIO BOLSONARO EXPANSÃO +CANDIDATOS VIA CONFIG
FASES 0 → 6 STATUS PLANEJAMENTO I

01 objetivo 02 escopo 03 fluxograma 04 fontes 05 fases 06 stack
07 riscos 08 métricas

01 Objetivo

Construir um **panorama contínuo da conversa pública** em torno dos políticos das eleições de 2026. O produto final é um dashboard que responde, para qualquer recorte de período e rede social:

1. **Sobre o que estão falando?** — tópicos dominantes por candidato, com evolução temporal (surgimento, pico e decaimento de temas).
2. **Como estão falando?** — sentimento por tópico × candidato × rede, priorizando a classificação tradicional em negativo, neutro e positivo; explicações do que puxou o sentimento entram como estudo complementar.
3. **Quem está falando?** — (fase exploratória) comunidades de usuários e como os temas circulam entre elas.

Princípio de arquitetura: candidatos e fontes são **entidades configuráveis**, não código fixo. Adicionar um novo político deve significar inserir uma linha de configuração (nome + apelidos + termos de busca), e o pipeline inteiro passa a coletar e analisar para ele.

02

Escopo de monitoramento

ENTIDADE 001 · V1

Lula

Presidente, provável candidato à reeleição.
Alto volume esperado em todas as redes.

aliases: "Lula", "Luiz Inácio", "Lula da Silva", "presidente Lula", hashtags associadas...

ENTIDADE 002 · V1

Flávio Bolsonaro

Senador, nome cotado do campo bolsonarista.

aliases: "Flávio Bolsonaro", "senador Flávio", handles oficiais...

ENTIDADES 003+ · PÓS-V1


Expansão planejada

Outros presidenciáveis, e depois governadores/senadores. Entram apenas via cadastro no registro de entidades (Fase 0) — nenhuma mudança de código.

03

Fluxograma da arquitetura

Versão completa do diagrama: fontes com status de viabilidade, camada de orquestração, armazenamento bruto e analítico separados, os três ramos de análise e o caminho até o dashboard.



04

Fontes de dados — viabilidade

FONTE	O QUE COLETAR	ACESSO	STATUS
YouTube	Comentários de vídeos que mencionam os candidatos; metadados dos vídeos e canais.	Data API v3 (gratuita, com quota diária — planejar paginação e priorização de vídeos).	VIÁVEL
Reddit	Posts e comentários em subreddits brasileiros de política.	API oficial via PRAW; limites generosos para leitura.	VIÁVEL
X / Twitter	Posts, respostas e engajamento — rede central do debate político.	API é paga e os tiers acessíveis têm limites baixos de leitura. Levantar custo real antes de assumir no escopo.	VERIFICAR
Instagram	Anúncios políticos pagos (texto, gasto, alcance, anunciante) — garantido. Posts e comentários: desejado, viabilidade em estudo.	Anúncios: Meta Ad Library API (oficial). Posts/comentários: estudar Graph API (limitada a contas autorizadas — cobre os perfis oficiais dos candidatos) e Meta Content Library (acesso para pesquisa, com processo de aprovação).	ANÚNCIOS OK POSTS: ESTUDAR
Facebook	Anúncios políticos pagos — garantido, mesmo conector do Instagram (Ad Library filtra por plataforma). Posts e comentários: desejado, viabilidade em estudo.	Mesmas vias do Instagram: Graph API para páginas oficiais dos candidatos; Meta Content Library como caminho para conteúdo público amplo. Resultado do estudo define o escopo final.	ANÚNCIOS OK POSTS: ESTUDAR

LGPD e termos de uso: coletar apenas conteúdo público via APIs oficiais; armazenar o mínimo de dados de autor (id/handle, nunca enriquecer com dados pessoais); anonimizar

autores comuns nas visualizações; documentar base legal e política de retenção antes de a coleta começar.

05 Fases do projeto

FASE 0 Fundação (nova — não existia no plano original) ~1–2 semanas

Preparar o terreno para que todas as fases seguintes sejam plugáveis.

1. **Registro de entidades:** cadastro de Lula e Flávio Bolsonaro com aliases e termos de busca (o mecanismo que permite expandir depois).
2. **Repositório + infraestrutura:** monorepo, Docker Compose (MongoDB, PostgreSQL, Redis), variáveis de ambiente, CI básico.
3. **Contratos de dados:** schema do documento bruto (comum a todas as fontes) e esboço do modelo analítico no PostgreSQL.
4. **Credenciais:** criar apps e chaves para YouTube, Reddit e Meta Ad Library; abrir a investigação de custo do X.
5. **Estudo de viabilidade IG/FB:** além dos anúncios, verificar se conseguimos extrair **posts e comentários** — testar Graph API nos perfis oficiais dos candidatos e iniciar o pedido de acesso à Meta Content Library. Saída: documento de decisão do que entra no escopo de coleta.

ENTREGÁVEIS repo funcional com docker compose up; entidades em config; schemas versionados.

PRONTO QUANDO um script de exemplo grava e lê um documento fake no MongoDB usando o schema oficial.

FASE 1 Coleta de dados ~2–3 semanas

Do plano original: coleta D-1 + MongoDB. Ampliado com orquestração, resiliência e observabilidade.

1. **Conectores por fonte** (YouTube, Reddit, Meta Ad Library p/ anúncios de Instagram e Facebook; X se aprovado): isolados, com retry/backoff e respeito a rate limits.

2. **Coleta incremental D-1:** agendada ao fim do dia via Airflow (uma DAG por fonte), com checkpoint da última coleta (nunca recoletar tudo).
3. **Deduplicação e validação:** id nativo da rede como chave; metadados obrigatórios (fonte, timestamp, autor, engajamento).
4. **Armazenamento bruto no MongoDB:** uma coleção por fonte, documento imutável como veio da API.
5. **Monitoramento de coleta:** volume por dia/fonte e alertas de falha — sem isso, buracos de dados só aparecem semanas depois.
6. **Tempo real:** avaliado, não implementado agora. Para as fontes escolhidas, evoluir de D-1 para intradiário (a cada 2–4h) cobre a necessidade com uma fração da complexidade de streaming.

ENTREGÁVEIS pipeline diário rodando sozinho por 7 dias seguidos; painel simples de volume coletado.

PRONTO QUANDO 7 dias consecutivos de coleta sem intervenção manual e sem lacunas.

Decisão registrada: "real-time" vira "intradiário" — para acompanhamento de temas eleitorais, latência de horas basta e custa uma fração da complexidade de streaming.

FASE 2 Modelagem de tópicos

~3–4 semanas

Descobrir sobre o que se fala quando se fala de cada candidato.

1. **Pré-processamento pt-BR:** limpeza de URLs/menções, mapeamento de emojis, normalização, detecção de idioma, remoção de spam evidente.
2. **BERTopic como baseline:** dentro da modelagem de tópicos, gerar embeddings Sentence-BERT/sentence-transformers como entrada do BERTopic e comparar o resultado com pelo menos uma alternativa (LDA ou outra técnica de tópicos) num conjunto fixo de avaliação.
3. **Um modelo por rede social** (linguagens muito diferentes entre Reddit e YouTube) + **alinhamento entre redes** por similaridade das representações dos tópicos, para o dashboard falar de "temas" únicos.
4. **Rotulagem dos tópicos:** nomes legíveis (via LLM com revisão manual) — "tópico 37" não serve para o painel.

5. **Persistência no PostgreSQL:** tópicos, pesos, distribuição por documento, candidato, rede e dia.
6. **Ciclo de operação (decidido): re-modelagem mensal** para capturar temas novos + **classificação diária:** todo documento coletado no dia é atribuído a um dos tópicos existentes via inferência do modelo vigente (transform do BERTopic sobre a representação gerada nessa etapa, sem re-treinar).
7. **Transição entre modelagens:** ao trocar o modelo no fim do mês, mapear tópicos novos ↔ antigos por similaridade das representações dos tópicos, para as séries temporais do dashboard não quebrarem; documentos com baixa afinidade a qualquer tópico ficam em "emergentes" e ajudam a justificar a próxima re-modelagem.

ENTREGÁVEIS tabela de tópicos nomeados por candidato × rede × dia; notebook de avaliação comparando modelos.

PRONTO QUANDO os 10 maiores tópicos de cada candidato fazem sentido para um revisor humano em 2 semanas distintas de dados.

FASE 3 API + Dashboard v1

~2–3 semanas

Tornar os tópicos visíveis e comparáveis — primeiro valor entregue ao usuário final.

1. **FastAPI:** endpoints de tópicos por candidato, séries temporais, comparativo entre candidatos, filtros de período/rede/entidade; paginação e cache (Redis) nas agregações pesadas.
2. **Dashboard React:** visão geral (volume de menções por candidato), evolução de tópicos no tempo (stream/área), comparativo lado a lado Lula × Flávio, drill-down de tópico com exemplos de posts.
3. **Seletor de entidades desde a v1:** mesmo com só 2 candidatos, o front já lista entidades vindas da API — quando a Fase 6 adicionar candidatos, o front não muda.
4. **Agregações pré-computadas:** tabela diária candidato × rede × tópico para o dashboard não fazer query pesada em tempo de página.

ENTREGÁVEIS dashboard navegável com dados reais; documentação OpenAPI automática.

PRONTO QUANDO uma pessoa de fora do projeto consegue responder "qual o tema da semana de cada candidato?" sozinha, em menos de 1 minuto.

FASE 4**Análise de sentimentos**

~3–4 semanas

Escolher empiricamente o melhor caminho para classificar sentimento político. O principal é a classificação tradicional em negativo, neutro e positivo; explicabilidade entra como estudo complementar.

1. **Estudo do estado da arte:** levantar algoritmos atuais para análise de sentimento em pt-BR e textos políticos, separando o problema principal (polaridade ternária) dos métodos de explicabilidade.
2. **Bases de avaliação:** usar datasets públicos ou bases já rotuladas existentes para negativo, neutro e positivo.
3. **Benchmark principal:** comparar algoritmos que classificam em negativo, neutro e positivo, medindo F1 macro, precisão/recall por classe quando a base permitir, custo, latência e facilidade de operação.
4. **Alvo do sentimento:** mapear o risco de confundir sentimento *sobre o candidato* com sentimento *sobre a situação comentada*. Isso entra como limitação documentada e pode virar uma etapa posterior se afetar muito o resultado.
5. **Explicabilidade (estudo paralelo):** avaliar métodos que indiquem quais trechos, palavras ou aspectos puxaram a classificação para positivo ou negativo. Só vira produto se agregar clareza real ao dashboard.
6. **Operação diária:** depois de escolhido o algoritmo, rodar inferência de sentimento nos documentos novos de cada dia; monitorar distribuição das classes, volume e confiança média para detectar comportamento estranho.
7. **Persistência e agregação:** sentimento por documento no PostgreSQL; série diária de sentimento por candidato × tópico × rede.
8. **Front:** integrar a análise de sentimento na mesma tela dos tópicos — cada tema mostra distribuição negativo/neutro/positivo no tempo por candidato e rede; explicações aparecem apenas se o estudo paralelo justificar.

ENTREGÁVEIS relatório de benchmark; algoritmo de polaridade escolhido com métricas documentadas; decisão go/no-go sobre explicabilidade; sentimento integrado à tela de tópicos.

PRONTO QUANDO o benchmark em bases existentes está documentado, o algoritmo de polaridade foi escolhido e a tela de tópicos exibe distribuição negativo/neutro/positivo por tema.

FASE 5 Comunidades (condicional)

~2 semanas de estudo + build se aprovado

Responder à dúvida do plano original: faz sentido, visto que já temos tópicos? Tratar como experimento com critério de decisão explícito.

1. **Estudo de valor analítico (gate):** que pergunta as comunidades respondem que tópicos + sentimento não respondem? Exemplo: "o tema X circula só numa bolha ou atravessou para outro campo?"
2. **Se aprovado:** grafo de interações por rede, detecção de comunidades (Leiden/Louvain), caracterização de cada comunidade pelos seus tópicos e sentimento dominantes.
3. **Front:** visualização de rede (força-dirigida) com filtro por tópico.
4. **Se reprovado:** documentar o porquê e realocar o tempo para a Fase 6.

ENTREGÁVEIS documento de decisão go/no-go; se go, grafo + visualização.

PRONTO QUANDO a decisão está registrada com pelo menos um exemplo concreto de insight que só a análise de comunidades revela.

FASE 6 Expansão e operação contínua

contínua até a eleição

Crescer o escopo sem crescer o retrabalho — e manter o sistema saudável até outubro de 2026.

1. **Novos candidatos:** adicionar presidenciáveis ao registro de entidades e validar que todo o pipeline (coleta → tópicos → sentimento → dashboard) os absorve sem mudança de código. Este é o teste real da arquitetura entity-driven.
2. **Alertas:** pico anômalo de volume ou virada brusca de sentimento sobre um candidato → notificação (e-mail/Telegram).
3. **Relatórios:** resumo semanal automático (top temas, variação de sentimento) por candidato.
4. **Backfill e reproprocessamento:** rotina para reproprocessar o histórico bruto do MongoDB quando modelos melhorarem — razão de manter a camada bruta imutável.

ENTREGÁVEIS 3º candidato ativo apenas via config; primeiro relatório semanal automático enviado.

PRONTO QUANDO adicionar um candidato leva < 1 dia de trabalho, do cadastro ao dashboard.

06

Stack de referência

CAMADA	ESCOLHA	POR QUÊ
Orquestração	Airflow (decidido)	DAGs separadas para coleta diária, classificação diária e re-modelagem mensal; retries e visibilidade de falhas nativos.
Coleta	Python (PRAW, google-api-python-client, requests)	Ecossistema maduro para todas as fontes escolhidas.
Bruto	MongoDB	Documentos heterogêneos por fonte, schema flexível, imutável.
NLP	BERTopic + sentence-transformers, modelos de sentimento pt-BR a definir, spaCy pt	BERTopic usa sentence-transformers para tópicos; sentimento será decidido por benchmark próprio.
Analítico	PostgreSQL	Modelo relacional para tópicos, sentimento e séries; agregações SQL para o dashboard.
API	FastAPI + Redis	Já previsto no plano original; Redis para cache de agregações.
Front	React (previsto no plano original) + biblioteca de gráficos (Recharts/ECharts)	Dashboard interativo com séries temporais e comparativos.
Infra	Docker Compose → VPS/cloud pequena	Reprodutível localmente; GPU só é necessária em janelas de treino/inferência batch.

07

Riscos e pontos de atenção

RISCO	IMPACTO	MITIGAÇÃO
Posts/comentários de IG e FB podem não ser viáveis	Panorama dessas redes ficaria restrito a anúncios pagos.	Estudo na Fase 0 com decisão documentada; Graph API dos perfis oficiais como piso garantido; anúncios já cobrem a comunicação paga.
Custo/limite da API do X	Perder a rede mais relevante do debate político.	Decidir cedo (Fase 0); YouTube + Reddit + anúncios da Meta já sustentam a v1 enquanto a decisão não sai.
Ironia/sarcasmo em política	Sentimento sistematicamente errado.	Registrar como limitação explícita no benchmark e preferir algoritmos que performem melhor em linguagem política informal quando houver evidência nas bases usadas.
Bots e campanhas coordenadas	Volume e sentimento distorcidos por atividade não orgânica.	Heurísticas simples na Fase 2 (contas repetitivas, burst de posts idênticos); flag de suspeita no documento.
Drift de tópicos	Modelo de fevereiro não conhece o escândalo de julho.	Re-modelagem mensal + fila de "emergentes" na classificação diária; mapeamento de ids entre modelagens por similaridade.
LGPD / termos das plataformas	Risco legal e bloqueio de credenciais.	Somente APIs oficiais e conteúdo público; minimização de dados de autor; política de retenção documentada.
Mudança de regras das APIs em ano eleitoral	Fonte pode fechar ou restringir no meio do projeto.	Conectores isolados (perder 1 fonte não derruba o pipeline); camada bruta preserva o histórico já coletado.

08

Métricas de sucesso

DIMENSÃO	MÉTRICA	META
Coleta	Dias sem lacuna de coleta / uptime do pipeline	≥ 95% dos dias sem intervenção manual
Tópicos	Coerência (c_v ou avaliação humana dos top-10 tópicos)	Top-10 legíveis e distintos para um revisor humano
Sentimento	Resultado do benchmark em bases públicas/existentes	Algoritmo escolhido com métricas, custo e limitações registrados
Produto	Tempo para responder "tema da semana de cada candidato"	< 1 minuto no dashboard, sem ajuda
Extensibilidade	Esforço para adicionar um novo candidato	< 1 dia, zero mudança de código

Próximos passos imediatos: ① abrir o repositório e o Docker Compose da Fase 0; ② cadastrar Lula e Flávio Bolsonaro no registro de entidades com aliases e termos de busca; ③ solicitar credenciais (YouTube, Reddit, Meta Ad Library), levantar o custo real da API do X e iniciar o estudo de posts/comentários de Instagram e Facebook.